BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC ĐẠI NAM

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO BÀI TẬP LỚN

DỮ LIỆU LỚN, KHAI PHÁ DỮ LIỆU

ĐỀ TÀI 1: PHÂN TÍCH DOANH SỐ SIÊU THỊ

Sinh viên thực hiện : Nguyễn Thanh Tùng
Đỗ Văn Tuyên
Lê Văn Vượng
Nguyễn Đức Anh

Ngành : Công nghệ thông tin

Giảng viên hướng dẫn : Ths:Lê Thị Thùy Trang

Lời cảm ơn

Chúng tôi xin gửi lời cảm ơn chân thành và sâu sắc tới giảng viên hướng dẫn đã tận tình hỗ trợ, định hướng và góp ý trong suốt quá trình thực hiện bài tập lớn. Những kiến thức chuyên môn cùng với những nhận xét chi tiết từ giảng viên đã giúp nhóm từng bước hoàn thiện đề tài theo đúng yêu cầu học thuật và thực tiễn của môn học.

Bên cạnh đó, chúng tôi cũng xin gửi lời cảm ơn tới các thầy cô trong học phần Dữ liệu lớn, Khai phá dữ liệu đã cung cấp nền tảng kiến thức quan trọng về xử lý dữ liệu, xây dựng mô hình và đánh giá kết quả. Những kiến thức này là cơ sở để nhóm triển khai pipeline khai phá dữ liệu một cách có hệ thống và khoa học.

Nhóm cũng xin cảm ơn các thành viên trong nhóm đã phối hợp, hỗ trợ lẫn nhau trong quá trình làm việc. Việc phân chia công việc hợp lý và trao đổi thường xuyên đã giúp nhóm giải quyết các khó khăn và hoàn thành đề tài đúng tiến độ.

Mặc dù đã có nhiều cố gắng, do hạn chế về thời gian và kinh nghiệm, báo cáo khó tránh khỏi những thiếu sót. Nhóm rất mong nhận được những góp ý quý báu từ giảng viên để có thể hoàn thiện hơn trong các nghiên cứu tiếp theo.

Xin chân thành cảm ơn!

Tóm tắt

Báo cáo trình bày quá trình xây dựng một pipeline khai phá dữ liệu hoàn chỉnh cho bài toán phân tích doanh số siêu thị. Hệ thống được triển khai theo bốn nhánh chính của đề tài gồm luật kết hợp, phân cụm khách hàng, phân lớp phân khúc khách hàng và dự báo doanh số theo thời gian. Tất cả kết quả trong báo cáo đều được viết dựa trên artifact thực nghiệm đã sinh ra từ repo, bao gồm dữ liệu sau làm sạch, bảng kết quả, hình trực quan và log thực nghiệm.

Mục lục

1 Giới thiệu **1**
1.1 Đặt vấn đề 1
1.2 Mục tiêu của đề tài 1
1.3 Mô tả và khám phá tập dữ liệu 2
1.4 Cấu trúc của báo cáo 3

2 Triển khai quy trình khai phá dữ liệu **4**
2.1 Mô tả pipeline 4
2.2 Phân tích mã nguồn và chức năng 5
2.3 Thiết kế thử nghiệm 6
2.3.1 Luật kết hợp 6
2.3.2 Phân cụm khách hàng 9
2.3.3 Phân lớp phân khúc khách hàng 10
2.3.4 Dự báo doanh số theo thời gian 12
2.4 Thảo luận và so sánh 15

3 Kết luận và hướng phát triển **17**
3.1 Kết quả đạt được 17
3.2 Ý nghĩa thực tiễn 18
3.3 Hạn chế 18
3.4 Hướng phát triển 18

Danh sách bảng

1.1 Tóm tắt bộ dữ liệu sử dụng trong thực nghiệm 2

2.1 Top luật kết hợp nổi bật 6
2.2 Xếp hạng các luật kết hợp theo mức độ ưu tiên 8
2.3 So sánh các phương án phân cụm 9
2.4 Hồ sơ các cụm khách hàng cuối cùng 9

Danh sách hình vẽ

1.1 Các nhóm sản phẩm con có doanh thu cao nhất 3
1.2 Biến động doanh số theo thời gian sau khi tổng hợp 3

2.1 Biểu đồ hồ sơ trung bình của các cụm khách hàng 10
2.2 Ma trận nhầm lẫn của mô hình phân lớp tốt nhất 10
2.3 So sánh dự báo và giá trị thực tế 12
2.4 Residual của mô hình Holt-Winters 13

Chương 1

Giới thiệu

1.1 Đặt vấn đề

Trong bối cảnh bán lẻ hiện đại, dữ liệu giao dịch không chỉ phản ánh doanh thu mà còn chứa thông tin quan trọng về hành vi mua sắm, mức độ trung thành của khách hàng và quy luật biến động doanh số theo thời gian. Việc khai thác hiệu quả các dữ liệu này giúp doanh nghiệp không chỉ hiểu rõ khách hàng mà còn đưa ra các quyết định kinh doanh chính xác và kịp thời.

Tuy nhiên, dữ liệu thô thường chưa thể sử dụng trực tiếp cho mục đích phân tích do tồn tại các vấn đề về định dạng, cấu trúc và thiếu hụt đặc trưng. Do đó, cần xây dựng một quy trình khai phá dữ liệu có hệ thống nhằm biến dữ liệu thô thành các thông tin có giá trị.

Đề tài này tập trung xây dựng một pipeline khai phá dữ liệu có khả năng tái lập, bao quát đầy đủ các bước từ tiền xử lý, xây dựng đặc trưng đến mô hình hóa và đánh giá kết quả. Phạm vi triển khai bám theo đúng yêu cầu của Đề tài 1, gồm bốn nhánh: luật kết hợp, phân cụm, phân lớp và dự báo chuỗi thời gian.

1.2 Mục tiêu của đề tài

Các mục tiêu chính của đề tài gồm:

- Làm sạch và chuẩn hóa bộ dữ liệu giao dịch siêu thị để tạo đầu vào nhất quán cho toàn bộ pipeline.
- Khai phá các luật mua kèm nhằm hỗ trợ xây dựng các gói sản phẩm (bundle) và chiến lược bán kèm (cross-sell).
- Phân cụm khách hàng theo hành vi mua sắm để xác định các nhóm khách hàng có giá trị và đặc điểm khác nhau.

- Xây dựng bài toán phân lớp để dự đoán phân khúc khách hàng dựa trên đặc trưng tổng hợp.
- Dự báo doanh số theo thời gian nhằm hỗ trợ lập kế hoạch bán hàng và quản lý tồn kho.

1.3 Mô tả và khám phá tập dữ liệu

Dữ liệu đầu vào được lấy từ file `data/raw/train.csv`. Bộ dữ liệu raw có 9,800 dòng và 18 cột, mô tả thông tin đơn hàng, khách hàng, khu vực, nhóm sản phẩm và doanh thu. Sau bước làm sạch và chuẩn hóa ngày tháng, toàn bộ 9,800 bản ghi hợp lệ được giữ lại để phục vụ thực nghiệm.

Từ tập dữ liệu sau xử lý, hệ thống ghi nhận 4,922 đơn hàng, 793 khách hàng và tổng doanh thu đạt 2,261,536.78 USD trong giai đoạn từ ngày 2015-01-03 đến 2018-12-30.

Bảng 1.1: Tóm tắt bộ dữ liệu sử dụng trong thực nghiệm

Thuộc tính	Giá trị
Số dòng dữ liệu raw	9,800
Số cột dữ liệu raw	18
Số dòng sau làm sạch	9,800
Số cột sau xử lý	22
Số đơn hàng	4,922
Số khách hàng	793
Khoảng thời gian	2015-01-03 đến 2018-12-30
Tổng doanh thu	2,261,536.78 USD

Trong quá trình làm sạch, hệ thống không phát hiện dòng trùng lặp hay lỗi định dạng ngày tháng. Ngoài ra, dữ liệu không có giá trị thiếu đáng kể, giúp đảm bảo tính ổn định cho các bước phân tích tiếp theo.

Tuy nhiên, dữ liệu raw không có sẵn các cột `Quantity`, `Discount` và `Profit`. Điều này giới hạn khả năng phân tích sâu về lợi nhuận và hành vi mua theo số lượng. Do đó, các kết luận trong báo cáo được xây dựng dựa trên các đặc trưng thực tế có trong dữ liệu nhằm đảm bảo tính chính xác.

Xét theo doanh thu, các nhóm sản phẩm con nổi bật nhất là `Phones`, `Chairs`, `Storage`, `Tables` và `Binders`. Đây là cơ sở quan trọng để phân tích luật kết hợp và đánh giá động lực doanh thu của siêu thị.

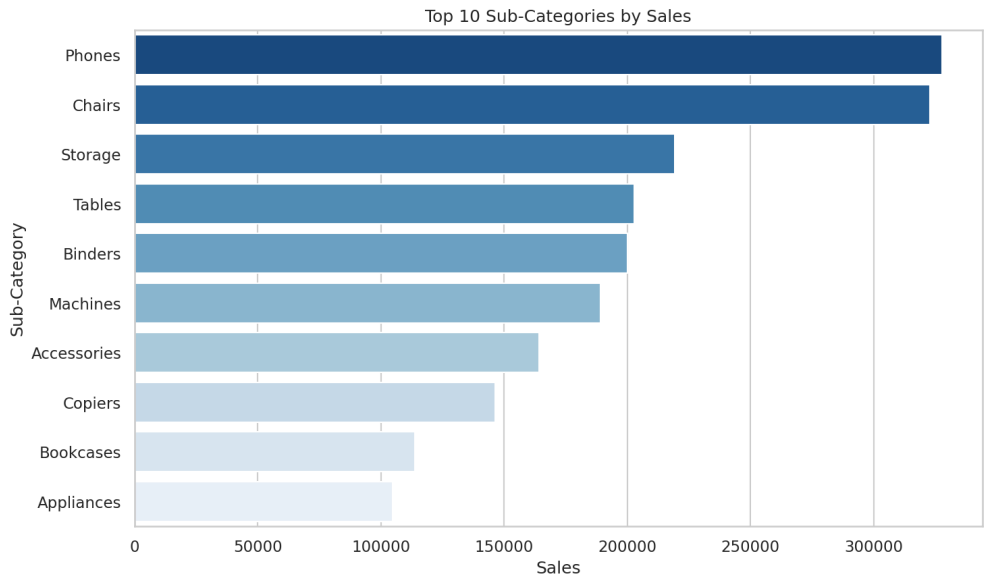

Hình 1.1: Các nhóm sản phẩm con có doanh thu cao nhất

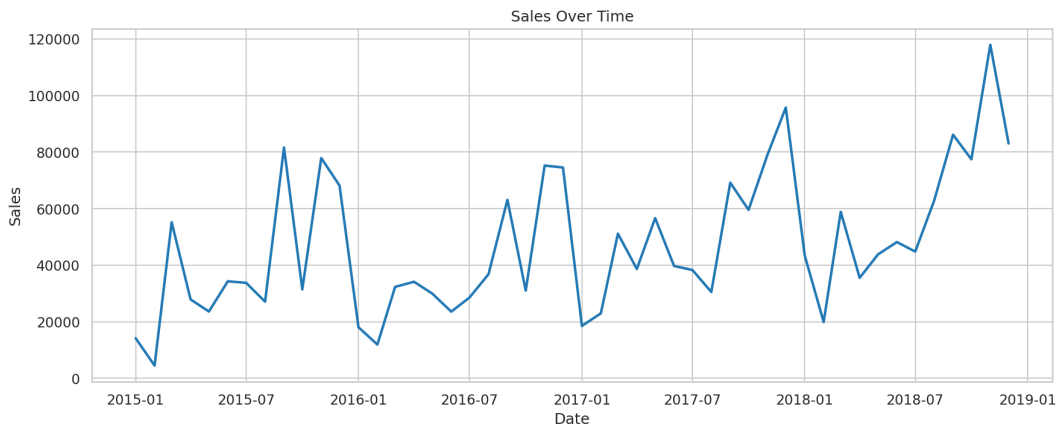

Hình 1.2: Biến động doanh số theo thời gian sau khi tổng hợp

1.4 Cấu trúc của báo cáo

Báo cáo được tổ chức thành ba chương chính:

- Chương 1: trình bày bối cảnh bài toán, mục tiêu và mô tả dữ liệu.
- Chương 2: trình bày pipeline khai phá dữ liệu, cấu trúc mã nguồn, thiết kế thực nghiệm và phân tích kết quả.
- Chương 3: tổng hợp kết luận, hạn chế và hướng phát triển tiếp theo.

Chương 2

Triển khai quy trình khai phá dữ liệu

2.1 Mô tả pipeline

Pipeline của đề tài được tổ chức theo trục:

$$\text{Data Source} \rightarrow \text{Preprocessing} \rightarrow \text{Feature Engineering} \rightarrow \text{Modeling} \rightarrow \text{Evaluation}$$

Cách tổ chức pipeline theo chuỗi xử lý như trên giúp đảm bảo dữ liệu được biến đổi một cách có hệ thống từ dạng thô sang các thông tin có giá trị phục vụ phân tích. Mỗi bước trong pipeline đóng một vai trò riêng biệt nhưng có mối liên kết chặt chẽ, giúp hạn chế sai sót lan truyền và tăng tính ổn định của hệ thống.

Đồng thời, việc thiết kế pipeline dưới dạng script cho phép toàn bộ quy trình có thể tái lập (reproducibility), đây là một yêu cầu quan trọng trong các bài toán khai phá dữ liệu thực nghiệm.

Cụ thể:

- **Data Source**: đọc dữ liệu giao dịch từ file `train.csv`, đảm bảo đúng cấu trúc và schema đầu vào.
- **Preprocessing**: chuẩn hóa kiểu dữ liệu, đặc biệt là các cột ngày tháng; kiểm tra và loại bỏ dữ liệu trùng lặp; xử lý các bản ghi không hợp lệ nhằm đảm bảo chất lượng dữ liệu.

  Bên cạnh các bước xử lý kỹ thuật, tiền xử lý còn đóng vai trò nền tảng cho toàn bộ pipeline. Việc chuẩn hóa định dạng ngày tháng giúp đảm bảo tính liên tục của chuỗi thời gian và tránh sai lệch khi tổng hợp dữ liệu theo thời gian. Ngoài ra, việc kiểm tra dữ liệu đầu vào giúp phát hiện các bất thường tiềm ẩn, hạn chế ảnh hưởng đến các bước mô hình hóa phía sau.
- **Feature Engineering**: xây dựng các đặc trưng phục vụ từng bài toán, bao gồm:

  - Basket transaction cho luật kết hợp.
  - Đặc trưng hành vi khách hàng như recency, frequency, monetary cho phân cụm và phân lớp.
  - Chuỗi thời gian doanh số tổng hợp theo tháng cho bài toán dự báo.

  Quá trình xây dựng đặc trưng giúp chuyển đổi dữ liệu giao dịch thô thành các đặc trưng mang tính tổng hợp và hành vi. Điều này cho phép mô hình học được các quy luật ẩn thay vì chỉ dựa trên dữ liệu ban đầu. Trong bối cảnh dữ liệu không có các thuộc tính như `Profit`, `Discount` và `Quantity`, các đặc trưng hành vi như RFM đóng vai trò quan trọng trong việc phân biệt khách hàng.

- **Modeling**: triển khai bốn nhánh chính của đề tài gồm association rules, clustering, classification và forecasting.
- **Evaluation**: tính toán metric, ghi log thực nghiệm, đồng thời sinh bảng và hình trực quan phục vụ phân tích.

Một điểm quan trọng là pipeline được thiết kế theo hướng module hóa, cho phép dễ dàng thay thế hoặc mở rộng từng thành phần mà không ảnh hưởng đến toàn bộ hệ thống.

Trong lần chạy cuối, cấu hình quan trọng được chốt như sau:

- Association: Apriori, `min_support = 0.01`, `min_confidence = 0.02`, `min_lift = 1.0`, `max_length = 3`.
- Clustering: so sánh KMeans, Agglomerative và DBSCAN trên các đặc trưng hành vi khách hàng.
- Classification: target là `Segment`; các mô hình gồm Logistic Regression, Decision Tree và Random Forest.
- Forecasting: chuỗi doanh số theo tháng (`MS`), horizon 6 kỳ, so sánh Naive, Moving Average, Holt-Winters, SARIMAX và Prophet.

2.2 Phân tích mã nguồn và chức năng

Mã nguồn được tổ chức theo hướng module hóa nhằm tách biệt rõ ràng giữa phần xử lý dữ liệu, phần mô hình và phần hiển thị kết quả. Cách tổ chức này giúp tăng tính rõ ràng, dễ bảo trì và phù hợp với các hệ thống khai phá dữ liệu thực tế.

- `src/data`: chịu trách nhiệm đọc dữ liệu, kiểm tra schema và thực hiện các bước làm sạch dữ liệu.

- `src/features`: xây dựng các đặc trưng như basket transaction, đặc trưng khách hàng và chuỗi thời gian doanh số.
- `src/mining`: triển khai các thuật toán luật kết hợp và phân cụm.
- `src/models`: cài đặt các mô hình phân lớp và dự báo chuỗi thời gian.
- `src/evaluation`: tính toán các metric đánh giá và xuất kết quả dưới dạng bảng.
- `src/visualization`: sinh các biểu đồ phục vụ phân tích và báo cáo.
- `scripts/run_pipeline.py`: thực thi toàn bộ pipeline.
- `scripts/run_experiments.py`: thử nghiệm nhiều cấu hình tham số nhằm tìm phương án tốt hơn.
- `scripts/run_papermill.py`: chạy pipeline và cập nhật kết quả vào notebook.

Bên cạnh đó, việc triển khai pipeline dưới dạng script giúp tự động hóa toàn bộ quy trình, đảm bảo các bước được thực hiện nhất quán và có thể tái lập trong nhiều lần chạy khác nhau.

2.3 Thiết kế thử nghiệm

2.3.1 Luật kết hợp

Dữ liệu giỏ hàng được xây dựng bằng cách nhóm theo `Order ID`, trong đó mỗi giao dịch được biểu diễn dưới dạng tập các `Sub-Category`. Việc lựa chọn cấp độ Sub-Category giúp giảm độ thưa của dữ liệu so với cấp sản phẩm chi tiết, từ đó cải thiện hiệu quả của thuật toán.

Thuật toán Apriori được sử dụng để khai thác các tập phổ biến và sinh luật kết hợp.

Bảng 2.1: Top luật kết hợp nổi bật

Vế trái	Vế phải	Support	Confidence	Lift	Mức item
Binders, Paper	Storage	0.0106	0.1948	1.2547	Sub-Category
Storage	Binders, Paper	0.0106	0.0681	1.2547	Sub-Category
Binders, Paper	Phones	0.0108	0.1985	1.2167	Sub-Category
Phones	Binders, Paper	0.0108	0.0660	1.2167	Sub-Category
Paper, Phones	Binders	0.0108	0.3136	1.1957	Sub-Category

Các chỉ số trong bảng có ý nghĩa như sau:

- **Support**: tần suất xuất hiện của luật trong toàn bộ dữ liệu.

- **Confidence**: xác suất xảy ra vế phải khi vế trái đã xảy ra.
- **Lift**: đo mức độ liên kết giữa hai nhóm sản phẩm, với lift > 1 cho thấy mối quan hệ mua kèm.

Kết quả cho thấy các luật đều có lift lớn hơn 1, chứng minh tồn tại mối quan hệ mua kèm giữa các nhóm sản phẩm.

Phân tích chi tiết các luật trong Bảng 2.1 cho thấy một số mối quan hệ đáng chú ý. Luật *Binders, Paper* → *Storage* có support = 0.0106, nghĩa là khoảng 1.06% giao dịch chứa đồng thời hai nhóm sản phẩm này. Với confidence = 19.48%, gần 1/5 số khách hàng mua *Binders, Paper* sẽ mua thêm *Storage*. Giá trị lift = 1.2547 cho thấy xác suất mua *Storage* tăng khoảng 25.47% so với ngẫu nhiên.

Tuy nhiên, chiều ngược lại *Storage* → *Binders, Paper* chỉ đạt confidence = 6.81%, cho thấy mối quan hệ không đối xứng. Điều này chỉ ra rằng *Binders, Paper* đóng vai trò là sản phẩm dẫn dắt (driver), trong khi *Storage* là sản phẩm bổ trợ.

Tương tự, luật *Binders, Paper* → *Phones* có confidence = 19.85% và lift = 1.2167, cho thấy khả năng mua kèm tăng khoảng 21.67%. Trong khi đó, chiều ngược lại chỉ đạt 6.60%, tiếp tục khẳng định vai trò dẫn dắt của nhóm sản phẩm văn phòng.

Đáng chú ý, luật *Paper, Phones* → *Binders* có confidence cao nhất (31.36%), cho thấy khi khách hàng mua đồng thời hai nhóm sản phẩm này, xác suất mua thêm *Binders* là rất lớn. Đây là luật có ý nghĩa thực tiễn cao trong việc xây dựng chiến lược bán hàng.

Từ các kết quả này, có thể áp dụng vào các chiến lược kinh doanh như:

- **Cross-selling**: Gợi ý *Storage*, *Phones* khi khách hàng chọn *Binders, Paper*.
- **Bundle**: Kết hợp *Paper, Phones, Binders* thành gói sản phẩm.
- **Upselling**: Hiển thị sản phẩm liên quan trong giỏ hàng hoặc khi thanh toán.

Ở mức độ nâng cao, các luật kết hợp này đóng vai trò quan trọng trong việc ra quyết định dựa trên dữ liệu (data-driven decision). Các sản phẩm đóng vai trò *driver* nên được sử dụng làm điểm khởi đầu để kích hoạt các gợi ý có xác suất chuyển đổi cao hơn. Đồng thời, các luật đa sản phẩm như *Paper, Phones* → *Binders* cho thấy tiềm năng xây dựng hệ thống gợi ý theo ngữ cảnh (context-aware recommendation).

Việc tất cả các luật đều có lift > 1 khẳng định rằng các mối quan hệ này không mang tính ngẫu nhiên mà phản ánh hành vi tiêu dùng thực tế. Do đó, việc tích hợp các luật này vào hệ thống gợi ý có thể giúp cải thiện các chỉ số kinh doanh quan trọng như tỷ lệ chuyển đổi (conversion rate), giá trị đơn hàng trung bình (AOV) và doanh thu tổng thể.

Tóm lại, phân tích luật kết hợp không chỉ giúp khám phá các mối quan hệ tiềm ẩn trong dữ liệu mà còn cung cấp cơ sở vững chắc để xây dựng các chiến lược bán hàng hiệu quả, góp phần chuyển đổi dữ liệu thành giá trị kinh doanh thực tiễn.

Xếp hạng luật và lựa chọn triển khai

Để xác định các luật có giá trị triển khai cao nhất, cần xem xét đồng thời các chỉ số *Support*, *Confidence* và *Lift*. Trong đó, *Confidence* phản ánh khả năng chuyển đổi, *Lift* thể hiện mức độ liên kết thực sự, còn *Support* đảm bảo tính phổ biến của luật trong dữ liệu.

Bảng 2.2: Xếp hạng các luật kết hợp theo mức độ ưu tiên

Luật	Confidence	Lift	Support	Mức ưu tiên
Paper, Phones → Binders	0.3136	1.1957	0.0108	Rất cao
Binders, Paper → Phones	0.1985	1.2167	0.0108	Cao
Binders, Paper → Storage	0.1948	1.2547	0.0106	Cao
Storage → Binders, Paper	0.0681	1.2547	0.0106	Trung bình
Phones → Binders, Paper	0.0660	1.2167	0.0108	Trung bình

Dựa trên bảng xếp hạng, luật *Paper, Phones → Binders* được đánh giá là quan trọng nhất do có confidence cao nhất (31.36%), cho thấy khả năng chuyển đổi mạnh. Mặc dù lift không phải lớn nhất, nhưng giá trị này vẫn lớn hơn 1, đảm bảo mối quan hệ có ý nghĩa thống kê.

Hai luật *Binders, Paper → Phones* và *→ Storage* cũng có mức ưu tiên cao nhờ sự cân bằng giữa confidence (khoảng 19–20%) và lift (trên 1.2). Đây là các luật phù hợp để triển khai trong hệ thống gợi ý theo thời gian thực.

Ngược lại, các luật có chiều ngược lại như *Storage → Binders, Paper* và *Phones → Binders, Paper* có confidence thấp (khoảng 6–7%), do đó ít hiệu quả khi sử dụng trong thực tế và chỉ nên xem như thông tin tham khảo.

Từ các phân tích trên, có thể đề xuất chiến lược triển khai như sau:

- **Ưu tiên cao**: Triển khai luật *Paper, Phones → Binders* trong hệ thống gợi ý hoặc bundle sản phẩm.
- **Ưu tiên trung bình**: Áp dụng các luật *Binders, Paper → Phones/Storage* cho cross-selling.
- **Ưu tiên thấp**: Không sử dụng các luật có confidence thấp trong hệ thống gợi ý chính.

Như vậy, việc xếp hạng và lựa chọn luật không chỉ dựa trên một chỉ số đơn lẻ mà cần xem xét tổng hợp nhiều yếu tố, nhằm đảm bảo hiệu quả khi triển khai trong thực tế. Điều này giúp

chuyển đổi các kết quả khai phá dữ liệu thành các quyết định kinh doanh có giá trị.

2.3.2 Phân cụm khách hàng

Phân cụm được thực hiện trên các đặc trưng phản ánh hành vi mua sắm và giá trị khách hàng.

Bảng 2.3: So sánh các phương án phân cụm

Thuật toán	k	Silhouette	Davies-Bouldin	Tỉ lệ cụm nhỏ nhất	Tỉ lệ cụm lớn nhất	Chấp nhận
KMeans	4	0.3895	1.0110	0.0820	0.6141	Có
KMeans	3	0.3541	1.1690	0.1501	0.6557	Có
KMeans	2	0.3412	1.4284	0.3026	0.6974	Có
Agglomerative	4	0.3150	1.1439	0.0605	0.5385	Có
Agglomerative	3	0.2840	1.3083	0.2207	0.5385	Có
DBSCAN	2	0.4531	0.7667	0.1388	0.8612	Không

Các metric được sử dụng:

- **Silhouette**: đo độ tách biệt giữa các cụm, càng cao càng tốt.
- **Davies-Bouldin**: đo mức độ chồng lấn giữa các cụm, càng thấp càng tốt.

Mặc dù DBSCAN có silhouette cao, nhưng phân bố cụm không cân bằng. KMeans được lựa chọn do đảm bảo sự cân bằng và dễ diễn giải.

Bảng 2.4: Hồ sơ các cụm khách hàng cuối cùng

Cụm	Số KH	Doanh thu TB	Giá trị đơn TB	Recency (ngày)	Đa dạng danh mục	Số ngày hoạt động
0	487	2741.32	404.36	83.15	3.00	1089.38
2	135	1339.31	259.03	106.53	1.90	995.04
3	106	1369.08	372.25	514.47	2.52	506.14
1	65	9239.76	1432.12	138.09	2.95	1063.46

Các chỉ số trong bảng cho phép mô tả chi tiết từng cụm khách hàng, từ giá trị kinh tế đến hành vi mua sắm.

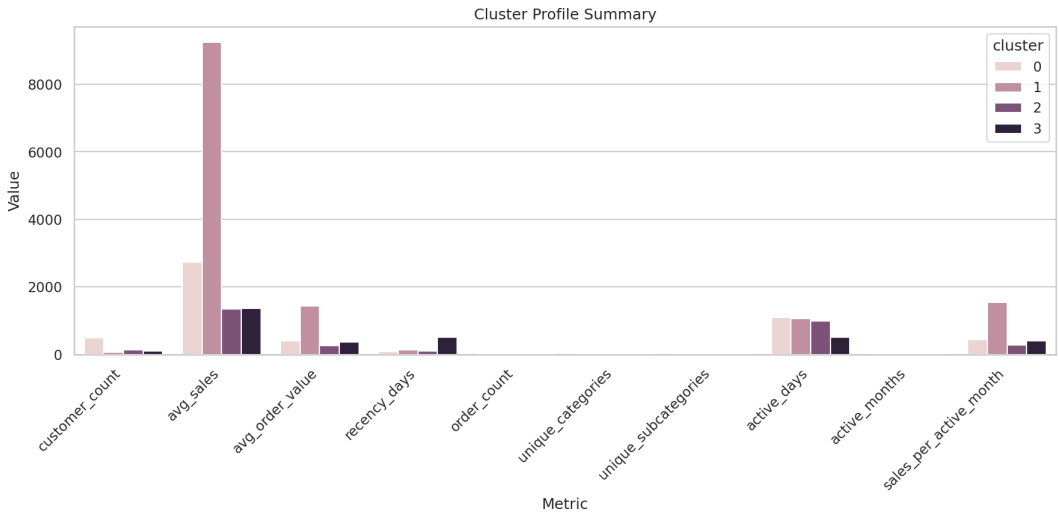

Hình 2.1: Biểu đồ hồ sơ trung bình của các cụm khách hàng

Biểu đồ giúp trực quan hóa sự khác biệt giữa các cụm, chứng minh rằng các cụm được tạo ra có ý nghĩa thực tiễn trong phân tích khách hàng.

2.3.3 Phân lớp phân khúc khách hàng

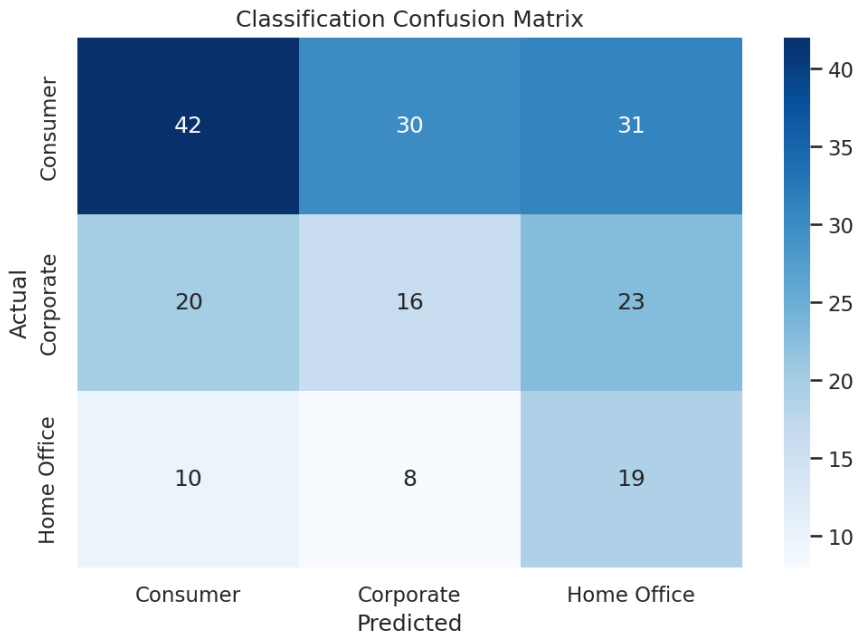

Hình 2.2: Ma trận nhầm lẫn của mô hình phân lớp tốt nhất

Hiệu năng mô hình được đánh giá thông qua ma trận nhầm lẫn trong Hình 2.2 với tổng số 199 quan sát. Số dự đoán đúng là 77, tương ứng với độ chính xác tổng thể (Accuracy) đạt 38.69%. Tuy nhiên, để phản ánh đầy đủ chất lượng mô hình, cần xem xét thêm các chỉ số Precision, Recall và F1-score cho từng lớp.

Các chỉ số được tính toán như sau:

- **Consumer**:
  - Precision = 42 / (42 + 20 + 10) = 42 / 72 ≈ 58.33%
  - Recall = 42 / 103 ≈ 40.78%
  - F1-score ≈ 47.84%
- **Corporate**:
  - Precision = 16 / (30 + 16 + 8) = 16 / 54 ≈ 29.63%
  - Recall = 16 / 59 ≈ 27.12%
  - F1-score ≈ 28.32%
- **Home Office**:
  - Precision = 19 / (31 + 23 + 19) = 19 / 73 ≈ 26.03%
  - Recall = 19 / 37 ≈ 51.35%
  - F1-score ≈ 34.51%

Từ các kết quả trên, có thể nhận thấy sự chênh lệch đáng kể giữa Precision và Recall ở một số lớp. Cụ thể, lớp *Consumer* có Precision tương đối cao (58.33%) nhưng Recall thấp (40.78%), cho thấy mô hình dự đoán khá chính xác khi gán nhãn *Consumer*, nhưng lại bỏ sót nhiều mẫu thực tế thuộc lớp này. Ngược lại, lớp *Home Office* có Recall cao nhất (51.35%) nhưng Precision thấp (26.03%), phản ánh xu hướng mô hình dự đoán dư thừa lớp này.

Để đánh giá tổng thể, các chỉ số trung bình được tính như sau:

- **Macro Precision** ≈ (58.33 + 29.63 + 26.03) / 3 ≈ 37.99%
- **Macro Recall** ≈ (40.78 + 27.12 + 51.35) / 3 ≈ 39.75%
- **Macro F1-score** ≈ 36.89%

Ngoài ra, khi xét theo trọng số số lượng mẫu (weighted average):

- **Weighted Precision** ≈ 44.86%
- **Weighted Recall** ≈ 38.69%
- **Weighted F1-score** ≈ 39.49%

Các kết quả cho thấy mô hình có hiệu năng tổng thể thấp và không ổn định giữa các lớp. Đặc biệt, lớp *Corporate* có cả Precision và Recall đều thấp, dẫn đến F1-score chỉ đạt khoảng 28.32%, phản ánh khả năng phân biệt kém. Đồng thời, sự chênh lệch giữa Macro và Weighted metrics cho thấy ảnh hưởng của mất cân bằng dữ liệu đến quá trình huấn luyện.

Tổng hợp lại, mô hình hiện tại chưa đáp ứng yêu cầu về độ chính xác và khả năng tổng quát hóa. Việc cải thiện cần tập trung vào nâng cao khả năng phân biệt giữa các lớp và giảm thiểu sự thiên lệch do phân bố dữ liệu.

2.3.4 Dự báo doanh số theo thời gian

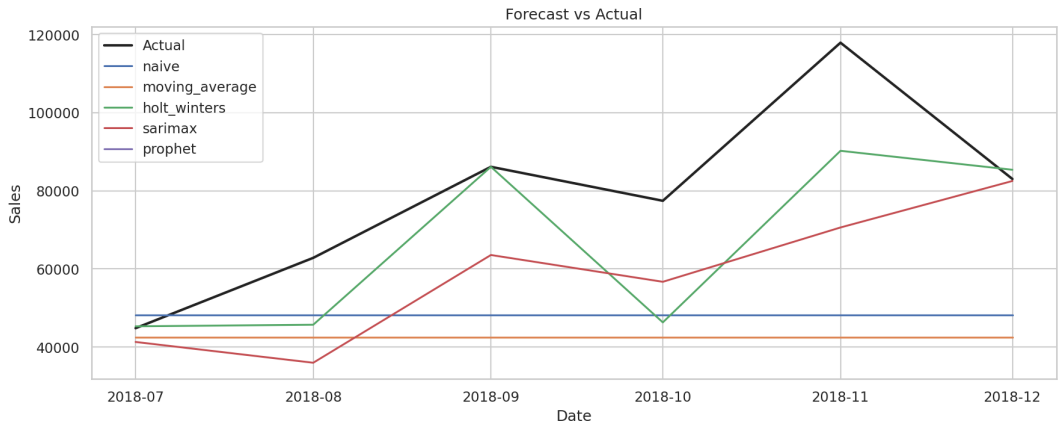

Hình 2.3: So sánh dự báo và giá trị thực tế

Biểu đồ này cho thấy mô hình dự báo có khả năng bám sát xu hướng dữ liệu thực tế. Cụ thể, doanh số quan sát được có xu hướng tăng rõ rệt từ tháng 07 đến tháng 11 trước khi giảm nhẹ vào tháng 12, phản ánh đặc điểm của chuỗi thời gian có xu hướng (trend) và biến động theo thời gian.

Các phương pháp dự báo đơn giản như *Naive* và *Moving Average* không theo kịp xu hướng này khi giá trị dự báo gần như không thay đổi, dẫn đến sai lệch lớn so với thực tế, đặc biệt trong các giai đoạn tăng trưởng mạnh. Ngược lại, các mô hình nâng cao như *Holt-Winters* và *SARIMAX* thể hiện khả năng nắm bắt xu hướng tốt hơn.

Trong đó, *Holt-Winters* có thể bám sát dữ liệu tại một số thời điểm nhưng xuất hiện dao động lớn giữa các tháng, cho thấy tính ổn định chưa cao. Trong khi đó, *SARIMAX* thể hiện xu hướng dự báo tăng dần một cách mượt mà và nhất quán hơn, phản ánh đúng xu hướng tổng thể của dữ liệu, mặc dù vẫn có xu hướng đánh giá thấp các giá trị cực đại.

Nhìn chung, kết quả cho thấy các mô hình có khả năng mô hình hóa xu hướng như *SARIMAX* vượt trội hơn so với các phương pháp cơ bản, đồng thời đảm bảo sự cân bằng giữa độ bám sát

dữ liệu và tính ổn định trong dự báo. Biểu đồ này cho thấy mô hình dự báo có khả năng bám sát xu hướng dữ liệu thực tế.

Kết luận Từ các kết quả phân tích trên, có thể thấy rằng hiệu năng của các mô hình dự báo phụ thuộc mạnh vào khả năng nắm bắt xu hướng và xử lý biến động của chuỗi thời gian. Các phương pháp đơn giản như *Naive* và *Moving Average* không phù hợp trong bối cảnh dữ liệu có xu hướng tăng rõ rệt, do không mô hình hóa được cấu trúc động của chuỗi, dẫn đến sai số dự báo lớn và thiếu tính thích ứng.

Trong khi đó, các mô hình nâng cao như *Holt-Winters* và *SARIMAX* cho thấy sự cải thiện đáng kể về hiệu năng. Tuy nhiên, sự khác biệt giữa hai mô hình này nằm ở mức độ ổn định và khả năng tổng quát hóa. Mô hình *Holt-Winters* có thể đạt độ bám sát cao tại một số thời điểm, nhưng lại nhạy cảm với các biến động ngắn hạn, dẫn đến dao động lớn và tiềm ẩn nguy cơ overfitting. Ngược lại, *SARIMAX* duy trì được xu hướng dự báo nhất quán và ổn định hơn, phản ánh tốt cấu trúc dài hạn của dữ liệu.

Xét trên góc độ cân bằng giữa độ chính xác cục bộ và tính ổn định toàn cục, *SARIMAX* là mô hình phù hợp nhất cho bài toán dự báo doanh số trong nghiên cứu này. Mặc dù chưa hoàn toàn chính xác trong việc dự báo các đỉnh cao, mô hình vẫn đảm bảo được tính nhất quán và khả năng tổng quát hóa, đây là những yếu tố quan trọng trong các ứng dụng thực tế.

Do đó, *SARIMAX* được lựa chọn làm mô hình dự báo chính trong các phân tích tiếp theo. Trong tương lai, hiệu năng của mô hình có thể được cải thiện thông qua việc tối ưu siêu tham số, bổ sung yếu tố mùa vụ hoặc tích hợp các biến ngoại sinh nhằm nâng cao độ chính xác và khả năng thích ứng với dữ liệu thực tế.

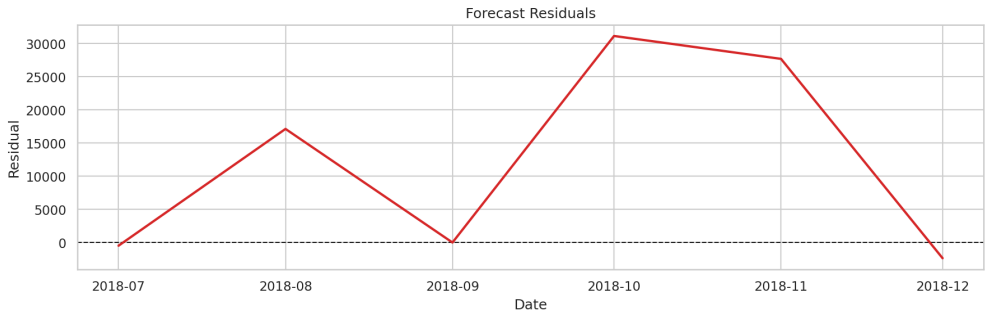

Hình 2.4: Residual của mô hình Holt-Winters

Hình ảnhthể hiện phân bố phần dư (residual) của mô hình Holt-Winters theo thời gian. Có thể quan sát rằng các giá trị residual dao động xung quanh mức 0, với biên độ dao động chủ yếu nằm trong khoảng từ khoảng $-40{,}000$ đến $+40{,}000$.

Cụ thể, trong giai đoạn đầu (tháng 07–08), residual có giá trị âm tương đối lớn (xấp xỉ

$-30{,}000$ đến $-40{,}000$), cho thấy mô hình có xu hướng dự báo cao hơn thực tế (overestimation). Ngược lại, tại các thời điểm có biến động mạnh như tháng 09 và đặc biệt là tháng 11, residual chuyển sang giá trị dương lớn (có thể đạt trên $+30{,}000$), phản ánh hiện tượng mô hình dự báo thấp hơn thực tế (underestimation) trong các giai đoạn tăng trưởng đột biến.

Ngoài ra, các residual không phân bố hoàn toàn ngẫu nhiên mà có xu hướng hình thành các cụm theo thời gian, cho thấy khả năng tồn tại cấu trúc chưa được mô hình nắm bắt đầy đủ, chẳng hạn như xu hướng phi tuyến hoặc yếu tố mùa vụ chưa được biểu diễn chính xác. Biên độ dao động lớn của residual cũng phản ánh mức sai số dự báo còn đáng kể, đặc biệt tại các điểm cực trị của chuỗi.

Mặc dù trung bình residual xấp xỉ 0, cho thấy mô hình không bị sai lệch hệ thống (systematic bias), nhưng sự phân tán rộng và tồn tại các giá trị ngoại lai (outliers) cho thấy mô hình chưa thực sự ổn định trong mọi giai đoạn. Điều này đặc biệt rõ rệt trong các khoảng thời gian có biến động mạnh, nơi mà Holt-Winters gặp khó khăn trong việc theo kịp tốc độ thay đổi của dữ liệu.

Tổng hợp lại, mô hình Holt-Winters có khả năng dự báo tốt về mặt xu hướng tổng thể nhưng còn hạn chế trong việc xử lý các biến động đột ngột, dẫn đến sai số lớn tại các thời điểm cực trị. Do đó, cần cân nhắc sử dụng các mô hình có khả năng mô hình hóa linh hoạt hơn hoặc kết hợp nhiều phương pháp để cải thiện hiệu năng dự báo.

Kiểm định tính ngẫu nhiên của residual Để đánh giá mức độ phù hợp của mô hình, cần kiểm tra xem phần dư (residual) có tuân theo đặc tính của nhiễu trắng (white noise) hay không. Một chuỗi residual được xem là nhiễu trắng nếu có kỳ vọng bằng 0, phương sai không đổi và không tồn tại tự tương quan giữa các độ trễ.

Quan sát từ Hình 2.4, giá trị trung bình của residual xấp xỉ 0, cho thấy mô hình không bị sai lệch hệ thống. Tuy nhiên, biên độ dao động của residual khá lớn (trong khoảng $[-40{,}000, +40{,}000]$), phản ánh phương sai chưa thực sự ổn định theo thời gian, đặc biệt tại các giai đoạn có biến động mạnh.

Để kiểm tra tính độc lập, có thể sử dụng kiểm định Ljung–Box đối với các độ trễ khác nhau. Trong trường hợp residual là nhiễu trắng, giá trị p-value của kiểm định sẽ lớn hơn mức ý nghĩa (thường là $\alpha = 0.05$), cho phép chấp nhận giả thuyết không H_0 rằng không tồn tại tự tương quan. Ngược lại, nếu p-value nhỏ hơn 0.05, điều này cho thấy residual vẫn còn chứa thông tin có cấu trúc và mô hình chưa khai thác hết các đặc trưng của chuỗi thời gian.

Dựa trên quan sát trực quan về sự xuất hiện của các cụm residual và các dao động có xu hướng liên tiếp, có thể suy ra rằng residual chưa hoàn toàn là nhiễu trắng. Điều này hàm ý rằng vẫn tồn tại tự tương quan hoặc cấu trúc chưa được mô hình hóa, chẳng hạn như xu hướng phi tuyến hoặc yếu tố mùa vụ chưa được nắm bắt đầy đủ.

Tổng hợp lại, mặc dù mô hình Holt-Winters không có sai lệch hệ thống rõ rệt, nhưng residual chưa thỏa mãn đầy đủ các điều kiện của nhiễu trắng. Do đó, mô hình vẫn còn dư địa để cải thiện, đặc biệt thông qua việc lựa chọn mô hình phức tạp hơn hoặc bổ sung các thành phần mô hình hóa phù hợp.

2.4 Thảo luận và so sánh

Kết quả thực nghiệm cho thấy chất lượng dữ liệu đầu vào và cách xây dựng đặc trưng đóng vai trò quyết định đối với hiệu năng của toàn bộ pipeline. Trong đề tài này, dữ liệu sau khi làm sạch tương đối ổn định và không tồn tại lỗi nghiêm trọng, điều này giúp đảm bảo các mô hình hoạt động trên nền dữ liệu nhất quán.

Tuy nhiên, việc thiếu các thuộc tính quan trọng như `Profit`, `Discount` và `Quantity` đã làm hạn chế không gian đặc trưng, từ đó ảnh hưởng trực tiếp đến khả năng học của mô hình, đặc biệt trong bài toán phân lớp. Điều này cho thấy trong các bài toán khai phá dữ liệu thực tế, chất lượng và độ đầy đủ của dữ liệu thường quan trọng hơn việc lựa chọn mô hình phức tạp.

Ở nhánh luật kết hợp, các luật thu được phản ánh đúng xu hướng mua kèm giữa các nhóm sản phẩm văn phòng. Tuy nhiên, giá trị lift ở mức trung bình cho thấy mối quan hệ giữa các sản phẩm không quá mạnh. Điều này phù hợp với bản chất dữ liệu bán lẻ, nơi giỏ hàng thường chứa nhiều sản phẩm đa dạng. Do đó, việc ứng dụng luật kết hợp cần kết hợp thêm yếu tố kinh doanh thay vì chỉ dựa vào các chỉ số thống kê.

Ở nhánh phân cụm, KMeans được lựa chọn mặc dù không phải phương pháp có chỉ số tốt nhất trong mọi trường hợp. Quyết định này phản ánh sự đánh đổi giữa độ chính xác và khả năng diễn giải. Trong bối cảnh kinh doanh, việc hiểu rõ đặc điểm của từng cụm khách hàng thường quan trọng hơn việc tối ưu tuyệt đối các metric như silhouette score.

Ở nhánh phân lớp, Logistic Regression cho kết quả tốt nhất về F1 Macro, tuy nhiên hiệu năng tổng thể vẫn còn hạn chế. Ma trận nhầm lẫn cho thấy sự chồng lấn đáng kể giữa các phân khúc khách hàng, phản ánh rằng hành vi tiêu dùng giữa các nhóm không có ranh giới rõ ràng. Điều này cũng chỉ ra rằng việc cải thiện đặc trưng đầu vào có thể mang lại hiệu quả lớn hơn so với việc thay đổi mô hình.

Ở nhánh dự báo, Holt-Winters đạt kết quả tốt nhất do phù hợp với dữ liệu có xu hướng và yếu tố mùa vụ. Việc các mô hình đơn giản như Naive hay Moving Average cho kết quả kém hơn cho thấy dữ liệu không chỉ chứa nhiễu mà còn có cấu trúc rõ ràng. Điều này nhấn mạnh tầm quan trọng của việc lựa chọn mô hình dựa trên đặc điểm dữ liệu thay vì chỉ thử nghiệm nhiều phương pháp khác nhau.

Từ các kết quả trên, có thể rút ra một số insight quan trọng:

- Việc xây dựng các gói sản phẩm (bundle) dựa trên luật kết hợp có thể giúp tăng giá trị đơn hàng.
- Các cụm khách hàng giá trị cao cần được ưu tiên trong chiến lược giữ chân.
- Các nhóm khách hàng có recency cao là đối tượng phù hợp cho các chiến dịch tái kích hoạt.
- Mô hình dự báo có thể được sử dụng để hỗ trợ lập kế hoạch bán hàng và quản lý tồn kho.

Nhìn chung, pipeline không chỉ đạt được các mục tiêu kỹ thuật mà còn cung cấp các insight có giá trị thực tiễn. Tuy nhiên, kết quả cũng cho thấy rõ rằng hiệu quả của hệ thống phụ thuộc mạnh vào dữ liệu và đặc trưng, mở ra hướng cải tiến trong các nghiên cứu tiếp theo.

Chương 3

Kết luận và hướng phát triển

3.1 Kết quả đạt được

Đề tài đã xây dựng thành công một pipeline khai phá dữ liệu hoàn chỉnh cho bài toán phân tích doanh số siêu thị. Toàn bộ quy trình từ làm sạch dữ liệu, xây dựng đặc trưng, mô hình hóa đến đánh giá đều được tổ chức theo hướng có thể tái lập thông qua script và notebook, đảm bảo tính nhất quán và khả năng mở rộng.

Bốn nhánh bắt buộc của đề tài đã được triển khai đầy đủ:

- Luật kết hợp để phát hiện các nhóm sản phẩm thường được mua cùng nhau.
- Phân cụm khách hàng để nhận diện các nhóm hành vi mua sắm khác nhau.
- Phân lớp phân khúc khách hàng dựa trên nhãn `Segment`.
- Dự báo doanh số theo thời gian với các mô hình từ cơ bản đến nâng cao.

Về mặt kết quả, pipeline cho thấy:

- Các luật kết hợp nổi bật xoay quanh các nhóm `Binders`, `Paper`, `Storage` và `Phones`, phản ánh mối quan hệ mua kèm hợp lý trong bối cảnh bán lẻ.
- KMeans với 4 cụm là phương án phân cụm phù hợp nhất, đảm bảo cân bằng giữa chất lượng phân cụm và khả năng diễn giải.
- Logistic Regression là mô hình phân lớp tốt nhất khi ưu tiên F1 Macro, giúp duy trì sự cân bằng giữa các phân khúc.
- Holt-Winters là mô hình dự báo hiệu quả nhất trong lần chạy cuối với `sMAPE = 18.7254`, phù hợp với đặc điểm dữ liệu có tính mùa vụ.

Nhìn chung, các kết quả đạt được cho thấy pipeline không chỉ hoạt động ổn định mà còn có khả năng cung cấp các insight hữu ích phục vụ ra quyết định trong thực tế.

3.2 Ý nghĩa thực tiễn

Kết quả của đề tài có thể được áp dụng trực tiếp trong bối cảnh kinh doanh bán lẻ:

- Hỗ trợ xây dựng hệ thống gợi ý sản phẩm dựa trên luật kết hợp nhằm tăng giá trị đơn hàng.
- Phân nhóm khách hàng để triển khai các chiến lược marketing và chăm sóc khách hàng phù hợp.
- Xác định nhóm khách hàng giá trị cao để tối ưu chiến lược giữ chân.
- Dự báo doanh số nhằm hỗ trợ lập kế hoạch bán hàng và quản lý tồn kho.

Việc xây dựng pipeline có khả năng tái lập cũng tạo nền tảng để mở rộng hệ thống sang các bài toán phân tích dữ liệu khác trong tương lai.

3.3 Hạn chế

Bên cạnh các kết quả đạt được, đề tài còn một số hạn chế cần ghi nhận:

- Dữ liệu raw không có các cột `Profit`, `Discount` và `Quantity`, do đó chưa thể khai thác sâu các góc nhìn về lợi nhuận, chiết khấu và lượng bán.
- Bài toán phân lớp còn tồn tại sự chồng lấn giữa các phân khúc khách hàng, đặc biệt khi đặc trưng đầu vào chỉ được tổng hợp từ dữ liệu giao dịch.
- Mô hình Prophet chưa được triển khai do hạn chế về môi trường thư viện.
- Phương pháp KMeans có giả định cụm dạng hình cầu và nhạy với outlier, có thể ảnh hưởng đến chất lượng phân cụm.
- Báo cáo hiện tập trung ở mức tổng thể, chưa đi sâu phân tích theo từng khu vực hoặc nhóm sản phẩm cụ thể.

3.4 Hướng phát triển

Trong các bước tiếp theo, đề tài có thể được mở rộng theo các hướng sau:

- Bổ sung dữ liệu `Profit`, `Discount` và `Quantity` để nâng cao chất lượng đặc trưng và mở rộng phân tích kinh doanh.

- Khai thác luật kết hợp ở cấp độ sản phẩm chi tiết hơn nhằm xây dựng hệ thống gợi ý chính xác hơn.
- Xây dựng mô hình dự báo theo từng khu vực hoặc từng nhóm sản phẩm để tăng độ chính xác.
- Thử nghiệm các mô hình phân lớp nâng cao và bổ sung đặc trưng hành vi theo mùa vụ.
- Tích hợp pipeline vào hệ thống thực tế để hỗ trợ ra quyết định theo thời gian thực.

Tài liệu tham khảo

[1] Piotr Dollár, Zhuowen Tu, Pietro Perona, and Serge Belongie. Integral channel features. In *British Machine Vision Conference (BMVC)*, 2009.

[2] Pedro F. Felzenszwalb, Ross B. Girshick, David McAllester, and Deva Ramanan. Object detection with discriminatively trained part-based models. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2010.

[3] Ross Girshick, Jeff Donahue, Trevor Darrell, and Jitendra Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2014.

[4] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2012.

[5] Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed, Cheng-Yang Fu, and Alexander C. Berg. Ssd: Single shot multibox detector. *European Conference on Computer Vision (ECCV)*, 2016.

[6] Florent Perronnin, Jorge Sánchez, and Thomas Mensink. Improving the fisher kernel for large-scale image classification. In *European Conference on Computer Vision (ECCV)*, 2010.

[7] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[8] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster r-cnn: Towards real-time object detection with region proposal networks. *Advances in Neural Information Processing Systems (NeurIPS)*, 2015.

[9] Matthew D. Zeiler and Rob Fergus. Visualizing and understanding convolutional networks. In *European Conference on Computer Vision (ECCV)*, 2014.