HƯỚNG DẪN THỰC HIỆN BÀI TẬP LỚN

HỌC PHẦN DỮ LIỆU LỚN, KHAI PHÁ DỮ LIỆU; KHAI PHÁ DỮ LIỆU -
HỌC KÌ II NĂM HỌC 2025–2026

ThS. Lê Thị Thùy Trang

2025-12-23

1 Mục tiêu của bài tập lớn

1.1 Về mặt kiến thức:

Sinh viên vận dụng kiến thức về khám phá dữ liệu (EDA), tiền xử lý, trích xuất/thiết kế đặc trưng, và các kỹ thuật khai phá dữ liệu đã học để xây dựng pipeline khai phá và đánh giá kết quả một cách khoa học.

Bài tập lớn tập trung vào các nhóm bài toán

- Khai phá mẫu/tri thức (association patterns)
- Phân cụm (clustering + diễn giải cụm)
- Phân lớp (classification) và bán giám sát khi thiếu nhãn
- Hồi quy/chuỗi thời gian (nếu đề tài thuộc nhóm dự báo)

1.2 Về mặt kỹ năng:

- Rèn luyện kỹ năng cốt lõi của một người làm dữ liệu: tiền xử lý, tạo đặc trưng, thử nghiệm–so sánh phương pháp và trình bày kết quả theo lập luận khoa học.
- Rèn luyện kỹ năng làm việc nhóm, nghiên cứu, viết báo cáo và thuyết trình dự án.

2 Yêu cầu chung

Sinh viên làm việc theo nhóm từ 2 đến 4 thành viên.

Đề tài bài tập lớn do giảng viên chỉ định theo danh sách đề bài ở phần 1danh sách đề tài.

Dataset sử dụng đúng link được cung cấp trong bảng đề tài; nhóm phải ghi rõ nguồn dữ liệu, mô tả cột, ý nghĩa nhãn/target (data dictionary).

Dự án **bắt buộc** thực hiện theo tinh thần "project repo": có cấu trúc thư mục rõ ràng, module hoá, chạy lại được (reproducible), KHÔNG sử dụng notebook rời rạc.

2.1 Quy trình khai phá dữ liệu tổng quát

Quy trình tổng quát tuân theo logic "Nguồn dữ liệu → Tiền xử lý → Đặc trưng/biểu diễn → Mô hình → Đánh giá" như sau:

1. Data Source (Nguồn dữ liệu): Dữ liệu dạng bảng/văn bản/ảnh/chuỗi thời gian/đồ thị… tùy đề tài.
2. Preprocessing (Tiền xử lý): Làm sạch, xử lý thiếu, chuẩn hoá, mã hoá biến phân loại, cân bằng lớp (nếu cần), tạo session (log), resample (time series)…
3. Feature / Representation (Đặc trưng/biểu diễn): TF-IDF/embeddings (text), đặc trưng ảnh, đặc trưng hành vi (RFM), lag features (chuỗi thời gian), graph features, vector hoá giỏ hàng…
4. Mining / Modeling (Khai phá, mô hình hoá)
   - Khai phá tri thức (bắt buộc): pattern mining / clustering / anomaly / rule extraction…
   - Mô hình dự đoán (nếu đề tài có supervised): classification/regression/forecasting; ghi rõ hyperparams, thời gian train, thiết lập thực nghiệm
5. Evaluation and Results (Đánh giá, kết quả): Dùng metric phù hợp, lập bảng/biểu đồ so sánh mô hình, kèm insight và khuyến nghị hành động.
6. Nhánh bổ sung: Bán giám sát (Semi-supervised) – chỉ áp dụng khi đề tài là phân lớp
   - Với đề tài phân lớp, nhóm phải thêm một nhánh thực nghiệm "thiếu nhãn":
   - Giữ lại p% nhãn (p = 5/10/20), phần còn lại coi là unlabeled
   - So sánh Supervised-only (ít nhãn) vs Semi-supervised (self-training/pseudo-label hoặc label spreading/propagation)
   - Báo cáo learning curve theo % nhãn và phân tích rủi ro pseudo-label

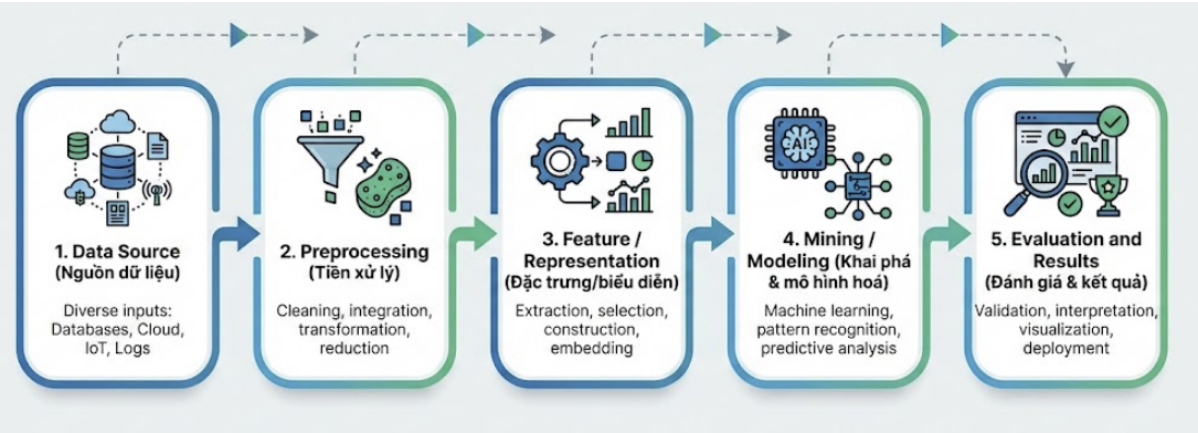

Figure 1: Pipeline project

2.2 Nội dung báo cáo (bắt buộc, theo đúng thứ tự)

Báo cáo phải có đủ các phần như sau:

1. Đặt vấn đề và phân tích yêu cầu: bối cảnh, mục tiêu, tiêu chí thành công; mô tả dữ liệu và EDA.
2. Thiết kế giải pháp và quy trình khai phá: mô tả pipeline; tiền xử lý; đặc trưng; lý do chọn kỹ thuật.

3. Phân tích mã nguồn và chức năng: tập trung mô tả kiến trúc repo, các module/class chính (DataCleaner/FeatureBuilder/Miner/Trainer/Evaluator…).
4. Thử nghiệm và kết quả: metric phù hợp; bảng/biểu đồ so sánh các phương án.
5. Thảo luận và so sánh: so sánh ưu/nhược; giải thích vì sao phương án A tốt hơn B; nêu thách thức gặp phải.
6. Tổng kết và hướng phát triển: tóm tắt kết quả và đề xuất cải tiến.

Ghi chú: Với nhóm có bán giám sát, phần (4)–(5) phải có thêm mục "thiếu nhãn: supervised vs semi-supervised".

2.3 Hình thức báo cáo

Báo cáo viết bằng LaTeX theo template do giảng viên cung cấp hoặc `.docx` theo mẫu của trường

Khuyến khích: trình bày nhiều hình/bảng, ít "dán code"; code nằm trong repo.

2.4 Sử dụng Github trong quá trình làm bài tập lớn

Sinh viên phải tổ chức project nhóm theo cấu trúc repo rõ ràng để đảm bảo dễ đọc – dễ chạy lại – dễ đánh giá. Repo cần tách bạch giữa dữ liệu, notebook báo cáo, mã nguồn (module), cấu hình tham số và kết quả đầu ra.

2.4.1 Cấu trúc repo mẫu

```
DATA_MINING_PROJECT/
 README.md
 requirements.txt            # hoặc environment.yml
 .gitignore
 configs/
    params.yaml            # tham số: seed, split, paths, hyperparams...
 data/
    raw/                   # dữ liệu gốc (không commit nếu quá lớn)
    processed/             # dữ liệu sau tiền xử lý (ưu tiên parquet/csv)
 notebooks/
    01_eda.ipynb
    02_preprocess_feature.ipynb
    03_mining_or_clustering.ipynb
    04_modeling.ipynb
    04b_semi_supervised.ipynb   # CHỈ áp dụng cho đề tài có bán giám sát
    05_evaluation_report.ipynb
 src/
    __init__.py
    data/
       __init__.py
       loader.py          # đọc dữ liệu, kiểm tra schema
       cleaner.py         # xử lý thiếu, outlier, encoding cơ bản
    features/
       __init__.py
       builder.py         # feature engineering (RFM, TF-IDF, lag, ...)
    mining/
```

```
      __init__.py
      association.py     # (nếu có) luật kết hợp / pattern
      clustering.py      # KMeans/HAC/DBSCAN + profiling
      anomaly.py         # (nếu có) outlier/anomaly
   models/
      __init__.py
      supervised.py      # train/predict cho classification/regression
      semi_supervised.py # CHỈ áp dụng cho đề tài có bán giám sát
      forecasting.py     # (nếu có) time series
   evaluation/
      __init__.py
      metrics.py         # accuracy, f1, auc, rmse, mae, ...
      report.py          # tổng hợp bảng/biểu đồ kết quả
   visualization/
       __init__.py
       plots.py           # hàm vẽ dùng chung
scripts/
   run_pipeline.py        # chạy toàn bộ pipeline (khuyến khích)
   run_papermill.py       # (khuyến khích) chạy notebook bằng papermill
outputs/
   figures/
   tables/
   models/
reports/
    final_report.pdf
```

2.4.2 Quy ước đặt tên luồng pipeline

Notebook đặt theo thứ tự 01 → 05 để người chấm chạy/đọc theo pipeline.

`src/` chứa toàn bộ logic chính; notebook chỉ gọi hàm/lớp và trình bày kết quả.

Tất cả đường dẫn và tham số quan trọng đặt trong configs/params.yaml.

2.4.3 Quy định về dữ liệu và lưu trữ

Không commit dữ liệu lớn vào GitHub.

Nếu dataset nặng, nhóm phải cung cấp:

- link dataset + hướng dẫn tải trong `README.md`, hoặc
- script tải dữ liệu trong `scripts/` (nếu có thể).

2.4.4 Yêu cầu tái lập

Repo được coi là đạt khi người khác có thể:

1. `pip install -r requirements.txt`
2. Cập nhật đường dẫn dữ liệu trong configs/params.yaml

3. Chạy `python scripts/run_papermill.py`
4. Thu được `outputs/` và hình/bảng đúng như báo cáo.

2.5 Điểm thưởng

Có GUI/Demo app (Streamlit/Gradio/web nhỏ): cộng điểm theo mức hoàn thiện

3 Danh sách đề tài bài tập lớn

Đề tài	Link dataset	Luật kết hợp	Phân cụm	Phân lớp	Bán giám sát	Hồi quy / Chuỗi thời gian
1. Phân tích doanh số siêu thị	Kaggle: Superstore Sales Dataset	Chuẩn hoá giỏ hàng theo hoá đơn. Chọn min_support/min_conf, xem lift. Top luật + gợi ý combo/cross-sell.	Đặc trưng RFM/giá trị/nhóm hàng. Chuẩn hoá. Hồ sơ cụm + insight.	Dự đoán phân khúc (LogReg/DT/RF). Đánh giá F1/ROC-AUC + phân tích lỗi.	Không thực hiện đối với đề tài này	Dự báo doanh số theo thời gian: split theo thời gian, baseline (naive/MA), ARIMA/Holt-Winters/Prophet, MAE/RMSE/sMAPE, phân tích residual/seasonality.
2. Dự đoán bệnh tim	UCI/Kaggle: Heart Disease Dataset	Rời rạc hoá chỉ số theo ngưỡng. Apriori tìm tổ hợp triệu chứng. Báo cáo support/conf/lift + diễn giải.	Chuẩn hoá đặc trưng. Mô tả cụm nguy cơ.	Phân lớp nguy cơ (SVM/RF/XGB). Imbalance: class_weight/SMOTE. Metric ưu tiên PR-AUC/F1 + phân tích lỗi.	*Tuỳ chọn (cân nhắc)* vì dữ liệu thường không quá lớn. Nếu làm: giả lập 10–30% nhãn, self-training với ngưỡng tin cậy cao, so sánh PR-AUC theo % nhãn, phân tích nhóm khó.	Hồi quy chỉ số (ví dụ huyết áp) theo yếu tố nguy cơ: Linear/Ridge vs XGBRegressor, MAE/RMSE, kiểm tra outlier/leakage; *Không bắt buộc áp dụng chuỗi thời gian*.
3. Phân tích cảm xúc khách hàng	Kaggle: Amazon Reviews Dataset	Tách review tích cực/tiêu cực. Apriori trên tập từ khoá/phrase. Top luật + diễn giải chủ đề.	TF-IDF/embeddings. Topic/cluster (K-means/HDBSCAN). Đặt tên cụm theo top terms. Silhouette + ví dụ đại diện.	Phân lớp sentiment (NB/Lo-gReg/SVM/LSTM). F1-macro + confusion matrix + phân tích lỗi (sarcasm, review ngắn).	Giả lập ít nhãn, label spreading/self-training, learning curve theo % nhãn, phân tích pseudo-label sai theo độ dài/độ hiếm từ.	Hồi quy rating từ nội dung: baseline (Ridge/Linear) + mô hình mạnh (SVR/XGB), MAE/RMSE. *Không bắt buộc áp dụng chuỗi thời gian*
4. Phân tích giao dịch ngân hàng	UCI: Bank Marketing Dataset	Tạo giỏ sản phẩm/dịch vụ theo khách. Top luật cross-sell. Đề xuất gói sản phẩm.	Phân cụm hồ sơ tài chính. Chuẩn hoá. Đặt tên cụm.	Dự đoán đăng ký term deposit (LogReg/RF/XGB). Imbalance. PR-AUC/F1 + giải thích đặc trưng.	Giả lập 10–30% nhãn, self-training, so sánh PR-AUC/lift@k theo % nhãn, phân tích pseudo-label sai theo campaign/nhóm tuổi.	Hồi quy số dư/tài chính theo tuổi/thu nhập: Linear/Ridge vs XGBRegressor, MAE/RMSE. *Không bắt buộc áp dụng chuỗi thời gian*
5. Dự báo thời tiết	Kaggle: Weather Dataset	Rời rạc hoá điều kiện. Tìm điều kiện đồng xuất hiện. So sánh theo mùa. Top luật + diễn giải.	Phân cụm ngày kiểu thời tiết. Chuẩn hoá. Hồ sơ cụm.	Phân lớp loại thời tiết (RF/XGB). F1-macro + phân tích lỗi giao mùa/cực trị.	*Không bắt buộc áp dụng học bán giám sát*	Sử dụng chuỗi thời gian dự báo nhiệt độ/độ ẩm: ACF/PACF, ARIMA/Holt-Winters, MAE/RMSE, residual + outlier.
6. Phân tích hiệu suất nhân viên	Kaggle: HR Analytics Dataset	Rời rạc hoá yếu tố. Tìm tổ hợp dẫn đến nghỉ việc. So sánh lift giữa stay vs leave. Gợi ý chính sách.	Phân cụm nhân viên. Chuẩn hoá. Profiling cụm.	Phân lớp nghỉ việc (XGB/RF). PR-AUC/F1 + giải thích SHAP.	Giả lập 10–30% nhãn, self-training, so sánh PR-AUC theo % nhãn, phân tích rủi ro gán nhãn sai (tác động chính sách).	Hồi quy mức độ hài lòng/điểm hiệu suất (nếu có): MAE/RMSE, kiểm tra leakage. *Chuỗi thời gian thường không phù hợp*
7. Dự báo năng suất cây trồng	Kaggle: Crop Yield datasets	Rời rạc hoá điều kiện (đất/thời tiết/giống). Apriori/ FP Growth tìm điều kiện đi kèm năng suất cao. Top luật + khuyến nghị canh tác (mức mô tả).	Phân cụm vùng trồng theo điều kiện. Chuẩn hoá. Profiling cụm + so sánh năng suất.	Sử dụng cột `Yield` (biến liên tục) làm nhãn:ép kiểu số cho Yield, loại bản ghi Yield bị thiếu/0 bất thường. Baseline + mô hình mạnh. F1 + phân tích lỗi vùng hiếm.	*Không yêu cầu áp dụng học bán giám sát*	Dự báo năng suất cây trồng: Baseline Linear/Ridge + RF/XGBRegressor. MAE/RMSE. *Chuỗi thời gian*: split theo năm, đánh giá drift/seasonality.
8. Phát hiện gian lận	Kaggle: Credit Card Fraud	Rời rạc hoá (amount/time bins). Tìm pattern thường gặp ở fraud. Top luật + lift (chỉ dùng như insight/feature).	Phân cụm/anomaly cluster (HDBSCAN/K-means). Chuẩn hoá. Đánh giá, mô tả cụm bất thường.	Phân lớp fraud/legit. Imbalance mạnh. PR-AUC + chọn ngưỡng theo chi phí sai. Phân tích false positive/negative.	Semi-supervised anomaly + thiếu nhãn. Giả lập ít nhãn fraud, self-training hoặc one-class/PU-learning (mức cơ bản), learning curve, phân tích rủi ro pseudo-label.	*Không yêu cầu sử dụng hồi quy và chuỗi thời gian*
9. Phân tích chất lượng nước	Kaggle: Water quality datasets	Rời rạc hoá chỉ số ô nhiễm. Apriori tìm chỉ số hay cùng tăng. Top luật + diễn giải theo ngưỡng an toàn.	Phân cụm nguồn nước theo profile. Chuẩn hoá. Chọn K. Profiling cụm + cảnh báo vùng rủi ro.	Phân lớp an toàn/không an toàn (nếu có nhãn/chuẩn). F1/PR-AUC + phân tích lỗi gần ngưỡng.	Giả lập ít nhãn, label spreading k-NN graph, learning curve, phân tích pseudo-label sai ở vùng ít mẫu.	Dự báo WQI hoặc chỉ số liên tục. MAE/RMSE. Dự báo các chỉ số chất lượng nước.
10. Dự báo nhu cầu năng lượng	UCI: Household Power Consumption	Nếu có thiết bị: basket thiết bị dùng cùng. Nếu không: rời rạc hoá trạng thái (peak/off-peak) rồi Apriori tìm đồng xuất hiện điều kiện.	Phân cụm hộ theo profile tiêu thụ. Chuẩn hoá. Phân cụm và Profiling (night-owl, peak-heavy...).	*Không áp dụng học bán giám sát* F1 + phân tích lỗi theo mùa.	*Không áp dụng hồi quy* Nhánh thay thế: anomaly mining (phát hiện ngày bất thường) kèm đánh giá.	Dự báo nhu cầu năng lượng Split theo thời gian. Baseline seasonal-naive. ARIMA/ETS/Holt-Winters. MAE/RMSE/sMAPE + residual + outlier.

Đề tài	Link dataset	Luật kết hợp	Phân cụm	Phân lớp	Bán giám sát	Hồi quy / Chuỗi thời gian
11. Phân tích đánh giá khách sạn & chủ đề dịch vụ	Kaggle: Hotel reviews datasets	Phân tích luật kết hợp trên từ khoá/khía cạnh (aspect) sau khi rời rạc hoá. Top luật dịch vụ đi kèm phàn nàn/khen.	Vector hoá. Phân cụm chủ đề (topic clusters). Đặt tên cụm + review đại diện.	Phân lớp sentiment/aspect. F1-macro + phân tích lỗi review đa chủ đề.	Thiếu nhãn aspect/sentiment theo domain. Giả lập ít nhãn, label spreading/self-training, learning curve, phân tích pseudo-label sai ở review ngắn.	Hồi quy rating. MAE/RMSE. *Không yêu cầu áp dụng chuỗi thời gian*
12. Dự đoán huỷ đặt phòng	Kaggle: Hotel Booking Demand dataset	Rời rạc hoá lead time/channel/country. Luật kết hợp tìm combo thuộc tính liên quan huỷ. So sánh theo mùa/quốc gia.	Phân cụm booking theo hành vi. Chuẩn hoá. Profiling cụm rủi ro huỷ cao.	Phân lớp huỷ/không huỷ. Imbalance. PR-AUC/F1. Kiểm tra leakage (thông tin sau đặt phòng).	Giả lập ít nhãn, self-training ngưỡng cao, learning curve, phân tích pseudo-label sai theo lead time dài.	*Không yêu cầu áp dụng hồi quy.* MAE/RMSE. Chuỗi thời gian dự báo cancellation rate theo tháng.
13. Dự đoán trả hàng TMĐT	Kaggle: E-commerce returns datasets	Rời rạc hoá cate-gory/shipping/promo. Luật kết hợp tìm combo liên quan trả hàng. Top luật + insight chính sách đổi trả.	Phân cụm khách/sản phẩm theo return rate. Chuẩn hoá. Profiling cụm rủi ro trả cao.	Phân lớp return/no-return. Imbalance. PR-AUC. Phân tích lỗi theo category.	Nhãn trả hàng có thể thiếu/đến muộn. Giả lập ít nhãn, self-training, learning curve, phân tích pseudo-label sai do promo/season.	*Không yêu cầu áp dụng hồi quy.* Chuỗi thời gian dự báo return rate theo tuần/tháng.
14. Dự báo giá/biến động crypto	Kaggle: Cryptocurrency Historical Prices dataset	Rời rạc hoá trạng thái (up/down/high-vol bins). Luật kết hợp tìm coin biến động cùng. Top luật + so sánh theo regime.	Phân cụm coin theo volatility/return/indica-tors. Chuẩn hoá. Profiling cụm (majors/high-risk...).	*Tuỳ chọn*: phân lớp trend up/down. ROC-AUC/F1 + phân tích lỗi khi tin tức sốc.	*Không yêu cầu áp dụng học bán giám sát*	Chuỗi thời gian dự báo price/return. Split theo thời gian, walk-forward. Baseline naive. ARIMA/ETS. MAE/RMSE + residual + volatility regime.
15. Phân nhóm học tập & dự đoán trượt môn	UCI: Student Performance	Rời rạc hoá hành vi (activity bins). Apriori tìm pattern hành vi đi kèm trượt/đỗ. Top luật + gợi ý can thiệp sớm.	Phân cụm sinh viên theo hành vi. Chuẩn hoá. Chọn K. Profiling cụm + khuyến nghị học tập.	Phân lớp pass/fail. PR-AUC/F1. Phân tích lỗi theo tuần học/nhóm yếu.	*Rất phù hợp*: nhãn kết quả chỉ có cuối kỳ, thiếu nhãn sớm. Giả lập ít nhãn, label spreading/self-training, learning curve, phân tích pseudo-label sai ở tuần đầu.	*Phù hợp (chuỗi thời gian)* với OULAD (theo tuần). Dự báo điểm/engagement theo tuần: split theo thời gian, baseline, ARIMA/ETS (hoặc mô hình đơn giản), MAE/sMAPE.
16. Phân tích lỗi sản xuất & dự đoán lỗi	UCI: AI4I 2020 Predictive Maintenance	Rời rạc hoá trạng thái máy (bin sensor/setting). Apriori tìm combo điều kiện liên quan lỗi. Top luật + insight vận hành.	Phân cụm máy/chu kỳ theo hành vi. Chuẩn hoá. Profiling cụm + lịch bảo trì.	Phân lớp lỗi/không lỗi (hoặc loại lỗi). Imbalance. PR-AUC/F1. Phân tích lỗi theo loại lỗi.	Áp dụng trong trường hợp nhãn lỗi hiếm/khó gán. Giả lập ít nhãn, self-training ngưỡng cao, learning curve, phân tích rủi ro pseudo-label (false alarm).	Sử dụng mô hình hồi quy dự đoán biến liên tục như `Tool wear [min]` (hoặc tự tạo `RUL/time-to-failure` từ `Machine failure`). MAE/RMSE. Dataset không có timestamp, chỉ có `UID` theo thứ tự; coi như time index để ARIMA/lag-features khi chấp nhận giả định "UID ≈ thời gian". Chia train/test theo thứ tự quan sát (không shuffle), đánh giá MAE/RMSE.

Table 1: Danh sách đề tài bài tập lớn

4 Rubic chấm điểm

Tiêu chí	Điểm tối đa	Đánh giá (Đạt / Trung bình / Chưa đạt)
A. Bài toán + mô tả dữ liệu + data dictionary	1.0	Đạt: Mục tiêu rõ ràng; mô tả nguồn dữ liệu; giải thích cột/nhãn/target; có data dictionary; nêu rủi ro như mất cân bằng lớp, thiếu dữ liệu, data leakage (nếu có). Trung bình: Có mô tả nhưng thiếu 1–2 ý quan trọng (ví dụ thiếu data dictionary hoặc chưa nói về leakage/imbalance). Chưa đạt: Mơ hồ; thiếu nguồn dữ liệu; không nêu target/label hoặc không giải thích dữ liệu.
B. EDA & tiền xử lý	1.5	Đạt: EDA có ít nhất 3 biểu đồ kèm diễn giải; xử lý missing/outlier/duplicate; encoding/scaling hợp lý; có thống kê trước–sau hoặc pipeline hoá. Trung bình: Có EDA và tiền xử lý nhưng phân tích còn nông; thiếu kiểm soát tham số hoặc thiếu thống kê trước–sau. Chưa đạt: EDA sơ sài hoặc chỉ chụp hình; tiền xử lý tuỳ tiện hoặc sai.
C. Data Mining core (pattern/cluster/anomaly/rule/graph)	2.0	Đạt: Có "khai phá tri thức" đúng chất (phân cụm/pattern/anomaly/rule/graph); trình bày tham số; có đánh giá (silhouette/DBI/coverage/runtime...); rút insight rõ ràng. Trung bình: Có mining nhưng hời hợt; thiếu đánh giá hoặc thiếu diễn giải kết quả. Chưa đạt: Không có phần mining; chỉ huấn luyện mô hình dự đoán.
D. Mô hình hoá + baseline so sánh (>= 2 baseline)	2.0	Đạt: Có ít nhất 2 baseline và 1 mô hình cải tiến; giải thích lựa chọn; có so sánh rõ ràng. Trung bình: Có baseline nhưng chưa rõ vai trò/thiết lập; thiếu so sánh hoặc mô hình cải tiến chưa thuyết phục. Chưa đạt: Chỉ 1 mô hình hoặc không có so sánh baseline.
E. Thiết kế thực nghiệm + metric đúng	1.0	Đạt: Split/CV hợp lý; đặt seed; tránh leakage; chọn metric phù hợp (F1/PR-AUC/ROC-AUC; RMSE/MAE/sMAPE; silhouette/DBI...). Trung bình: Có thực nghiệm nhưng thiếu kiểm soát (seed/leakage); metric đúng nhưng giải thích chưa rõ. Chưa đạt: Thiết kế thực nghiệm sai; metric không phù hợp hoặc không nêu rõ.
F. Bán giám sát hoặc nhánh thay thế tương đương	1.0	Đạt: *Nếu đề tài phân lớp:* có kịch bản thiếu nhãn (10–30% labeled), so sánh supervised-only vs semi-supervised (self-training/label spreading), có learning curve theo % nhãn và phân tích pseudo-label sai. Trung bình: Có triển khai nhưng thiếu một phần (thiếu learning curve/thiếu phân tích lỗi/thiếu so sánh). Chưa đạt: Không thực hiện semi-supervised (khi bắt buộc) hoặc không có nhánh thay thế (khi không áp dụng).
G. Đánh giá, phân tích lỗi & insight hành động	1.5	Đạt: Có phân tích lỗi (confusion matrix/residual); nêu dạng sai phổ biến; có ít nhất 5 insight "có hành động" (actionable) gắn với kết quả. Trung bình: Có insight nhưng chung chung; phân tích lỗi còn nông. Chưa đạt: Không phân tích lỗi; insight mơ hồ hoặc không có khuyến nghị.
H. Repo GitHub chuẩn + chạy lại được (reproducible)	1.0	Đạt: Repo đúng cấu trúc; có README, requirements/environment; có configs/outputs; chạy lại tạo ra kết quả; notebook "sạch" (gọi code từ src). Trung bình: Repo tương đối ổn nhưng thiếu 1–2 phần (ví dụ thiếu script chạy pipeline hoặc thiếu hướng dẫn); vẫn còn nhiều code trong notebook. Chưa đạt: Repo lộn xộn; thiếu hướng dẫn; không chạy lại được.

Table 2: Thang đánh giá đề tài bài tập lớn